МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ

ЛЬВІВСЬКИЙ НАЦІОНАЛЬНИЙ УНІВЕРСИТЕТ ІМЕНІ ІВАНА ФРАНКА

Факультет прикладної математики та інформатики
(повне найменування назва факультету)

Кафедра дискретного аналізу та інтелектуальних систем
(повна назва кафедри)

Курсова робота

РОЗРОБКА СИСТЕМИ ДЛЯ АВТОМАТИЧНОГО ВИЯВЛЕННЯ ФЕЙКОВИХ НОВИН

Виконав: студент групи ПМі-33с
спеціальності
122 «Комп'ютерні науки»
(шифр і назва спеціальності)

Яценко В.Т.
(підпис) (прізвище та ініціали)

Керівник Пелюшкевич О. В.
(підпис) (прізвище та ініціали)

Рецензент
(підпис) (прізвище та ініціали)

2025

ПЕРЕЛІК УМОВНИХ ПОЗНАЧЕНЬ І ТЕРМІНІВ

ШІ (англ. Artificial Intelligence, AI) - Штучний інтелект

TF-IDF (англ. TF - term frequency, IDF - inverse document frequency) - статистична міра для оцінки важливості слова в документі, що є частиною колекції або корпусу.

Векторизація - процес перетворення текстових даних у числовий формат

Accuracy - точність класифікації, частка правильно класифікованих зразків

Precision - точність, частка правильно визначених позитивних прикладів серед усіх визначених як позитивні

Recall - повнота, частка правильно визначених позитивних прикладів серед усіх фактично позитивних

F1-score - гармонійне середнє між precision та recall

Baseline (базова лінія) - початкова модель з простою архітектурою
що використовується як точка відліку для порівняння з більш складними рішеннями

Лематизація - процес приведення слів до їх базової форми (леми)

Токенізація - процес розбиття тексту на окремі одиниці (токени),
зазвичай слова або символи

Стоп-слова - часто вживані слова (прийменники, сполучники), які
зазвичай не несуть семантичного навантаження та видаляються при аналізі тексту

Датасет (англ. Dataset) - структурований набір даних для тренування
та тестування моделей машинного навчання

Імплементація - практична реалізація алгоритму або методу у вигляді програмного коду

API (Application Programming Interface) - набір правил та протоколів для взаємодії між програмними компонентами

Open-source - модель розробки програмного забезпечення з відкритим вихідним кодом, доступним для вільного використання та модифікації

ВСТУП

Сучасний інформаційний простір характеризується безпрецедентними обсягами та швидкістю поширення даних. Соціальні мережі, онлайн-медіа та месенджери стали основними джерелами новин для значної частини населення, що створює як нові можливості для доступу до знань, так і суттєві виклики у контексті оцінки якості та достовірності контенту. По-перше, традиційні механізми перевірки інформації не встигають за темпами її поширення в цифровому середовищі. По-друге, поряд із достовірною інформацією цими ж каналами активно поширюється дезінформація, маніпулятивний контент та фейкові новини. Це явище становить серйозну загрозу для суспільної стабільності, демократичних процесів та національної безпеки, особливо в умовах гібридних війн та цілеспрямованих інформаційних атак. За даними дослідження Reuters Institute Digital News Report 2023, яке охоплює 46 країн світу, 56% користувачів стурбовані тим, що не можуть відрізнити правдиву інформацію від фейкової в інтернеті [1]. В Україні ситуація є особливо критичною через триваючу інформаційну війну, що супроводжує військову агресію, де дезінформація використовується як інструмент гібридної вйіни для підриву довіри до державних інституцій та міжнародної підтримки. Водночас, зростаюча роль генеративних моделей штучного інтелекту у створенні правдоподібних, але фактично хибних повідомлень ускладнює ситуацію, роблячи фейкові новини все складнішими для розпізнавання людиною.

Сучасний стан проблеми розкривається в низці викликів, таких як обмежена масштабованість традиційного фактчекінгу, який виконується експертами вручну, відсутність єдиних стандартів перевірки достовірності інформації в україномовному сегменті, та необхідність швидкої реакції на інформаційні атаки. Традиційні методи верифікації новин часто не встигають за темпами генерації та поширення неправдивого контенту. Ці проблеми підкреслюють необхідність розвитку нових, автоматизованих підходів до виявлення фейкових новин, які б забезпечували швидкість, точність та масштабованість аналізу.

Актуальність даної роботи полягає у необхідності розробки та впровадження нових технологічних рішень, спрямованих на автоматизацію процесів виявлення недостовірної інформації. Технології машинного навчання та обробки природної мови можуть стати відповіддю на вищезгадані проблеми, гарантуючи швидку та ефективну фільтрацію інформаційних потоків. Такі системи дозволяють створювати моделі, що розрізняють характеристики правдивих та фейкових повідомлень на основі великих обсягів даних, сприяючи підвищенню стійкості суспільства до дезінформації.

Мета даної роботи полягає у розробці та реалізації моделей машинного навчання для автоматичного виявлення фейкових новин у текстових даних. Ця система має на меті забезпечити точну класифікацію новин за достовірністю та тематикою, одночасно акцентуючи увагу на доступності та зручності у використанні для кінцевих користувачів через веб-інтерфейс.

Розробка системи виявлення фейкових новин передбачає комплексний аналіз існуючих підходів та методів, виявлення прогалин та можливостей для вдосконалення. Також вона включає оцінку різних технологій машинного навчання, зокрема методів векторизації тексту, алгоритмів класифікації та архітектур нейронних мереж, на основі точності, швидкості роботи та придатності для україномовних даних. Вибір цих технологій базується на вимогах і цілях проєкту. Створення системи включає етапи збору та попередньої обробки даних, побудови та тренування моделей, тестування та розгортання. Користувацький інтерфейс також детально описується, включаючи функціональні можливості та принципи взаємодії з користувачем, щоб забезпечити інтуїтивно зрозумілу та доступну систему для всіх.

Основними завданнями даної курсової роботи є дослідження існуючих підходів до автоматичного виявлення фейкових новин та тематичної класифікації тексту, збір та підготовка корпусу україномовних новин, статистичний аналіз текстових даних, розробка базової моделі на основі логістичної регресії з використанням TF-IDF векторизації, дослідження більш складних архітектур, зокрема нейронних мереж, оцінка ефективності розроблених моделей за

допомогою метрик якості (accuracy, precision, recall, F1-score), та створення веб-додатку для демонстрації роботи моделей.

Результатом роботи є веб-додаток для виявлення фейкових новин, який є зручною платформою, здатною аналізувати текстовий контент та надавати прогноз щодо його достовірності. Систему можна застосовувати в медіа-моніторингу, на соціальних платформах, в освітніх закладах та для особистого використання. Медіа-компанії можуть використовувати її для попередньої фільтрації контенту та маркування потенційно недостовірної інформації, а освітні заклади - для підвищення медіаграмотності студентів. Дослідники медіа можуть застосовувати систему для аналізу інформаційних потоків та вивчення механізмів поширення дезінформації. Це ключовий момент, який допомагає суспільству протистояти інформаційним маніпуляціям та розвивати критичне мислення при споживанні новин.

1 ПОСТАНОВКА ЗАДАЧІ ТА ОГЛЯД НАЯВНИХ РІШЕНЬ

1.1 Огляд наявних рішень

Сучасні підходи до верифікації інформації можна розділити на кілька категорій залежно від рівня автоматизації та цільової аудиторії.

Професійні фактчекінгові платформи представляють собою інструменти для журналістів та дослідників, що дозволяють систематизувати процес перевірки фактів. Компанія Google розробила Fact Check Explorer [2] – пошукову систему, яка агрегує результати перевірок фактів від понад 100 організацій по всьому світу. Інструмент дозволяє шукати за ключовими словами або URL-адресами та отримувати інформацію про те, чи перевірявся цей факт раніше. Для розробників Google пропонує Fact Check Tools API [3], який дозволяє інтегрувати функціонал перевірки фактів у власні додатки.

В українському сегменті провідну роль відіграють спеціалізовані фактчекінгові організації. Проєкт StopFake [4], заснований у 2014 році, спеціалізується на спростуванні дезінформації про Україну у міжнародних та російських ЗМІ. Проте процес верифікації відбувається вручну експертами, без автоматизованих систем аналізу текстового контенту. Аналогічний підхід використовує платформа "Детектор медіа" з проєктом VoxCheck [5], яка фокусується на перевірці заяв українських політиків та публічних осіб.

Український сервіс FakeCheck.in.ua [6] пропонує інтерактивний підхід до оцінки достовірності новин, де користувач відповідає на серію запитань про джерело, автора та контент повідомлення, отримуючи ймовірнісну оцінку фейковості. Однак такий метод базується на суб'єктивних оцінках користувача та не використовує автоматичний аналіз текстового контенту засобами машинного навчання.

Ініціатива "Перевірка разом" від Gwara Media [7] представляє собою Telegram-бот для перевірки новин, який працює у напівавтоматичному режимі: користувачі надсилають посилання на новини, а команда фактчекерів перевіряє їх

та повертає результат. Це рішення частково автоматизує процес комунікації, проте сама верифікація залишається ручною.

Міжнародні платформи, такі як PolitiFact [8] (США), використовують систему рейтингів від "True" до "Pants on Fire" для оцінки достовірності заяв. Дослідницький проєкт Університету Саймона Фрейзера [9] демонструє систему автоматичного аналізу новин з використанням машинного навчання, однак тестування показало обмежену ефективність для україномовного контенту через відсутність адаптації моделей до особливостей української мови та специфіки локального контексту.

Основним обмеженням існуючих фактчекінгових інструментів є відсутність повної автоматизації: традиційні сервіси базуються на ручній роботі експертів, що робить неможливим масштабування для аналізу великих обсягів контенту в реальному часі. Інтерактивні калькулятори фейків покладаються на суб'єктивну оцінку користувачів. Існуючі ML-рішення демонструють недостатню ефективність для україномовного контенту через брак якісних датасетів та адаптованих моделей.

1.2 Постановка задачі

У курсовій роботі було поставлено за мету розробити систему автоматичного виявлення фейкових новин для україномовного контенту з використанням методів машинного навчання та обробки природної мови.

Система має забезпечити бінарну класифікацію новин (правдива/фейкова) та додаткову тематичну категоризацію контенту, надаючи користувачам швидкий та об'єктивний інструмент для оцінки достовірності інформації через зручний веб-інтерфейс. Для досягнення поставленої мети необхідно вирішити наступні задачі:

- Збір та формування корпусу україномовних новин з верифікованими мітками достовірності (правдива/фейкова) та тематичними категоріями.
- Дослідження та імплементація методів попередньої обробки текстових даних, включаючи токенізацію, видалення стоп-слів, лематизацію та векторизацію для україномовного контенту.

- Розробка базової моделі класифікації на основі логістичної регресії з використанням TF-IDF векторизації для встановлення baseline метрик якості.
- Дослідження та імплементація більш складних архітектур машинного навчання, зокрема нейронних мереж, для підвищення точності детекції.
- Проведення порівняльного аналізу розроблених моделей за метриками accuracy, precision, recall та F1-score на тестовій вибірці.
- Розробка веб-додатку з інтуїтивним користувацьким інтерфейсом для демонстрації роботи моделей, що дозволяє користувачам вводити текст новини та отримувати прогноз щодо її достовірності та тематики.
- Розгортання системи на публічному хостингу та забезпечення її доступності через веб-інтерфейс.

1.3 Проєктування вимог

Вимоги до програмного забезпечення визначають характеристики та обмеження системи, які необхідно реалізувати для досягнення поставленої мети. Вони поділяються на функціональні, що описують конкретні можливості та поведінку системи, та нефункціональні, що визначають якісні характеристики та обмеження, за яких система має функціонувати. Чітко сформульовані вимоги є основою для проєктування архітектури, розробки, тестування та оцінки успішності проєкту.

Для візуалізації функціональних вимог системи розроблено UML діаграму прецедентів, яка представлена на рисунку 1.1.

Діаграма прецедентів відображає основні сценарії взаємодії користувача з системою виявлення фейкових новин. Архітектура системи логічно розділена на дві взаємопов'язані підсистеми: введення та обробка (ліва частина діаграми) та аналіз результатів (права частина діаграми).

Користувач виступає єдиним актором системи та має доступ до всього функціоналу через веб-інтерфейс. Взаємодія користувача з системою відбувається

через вісім основних прецедентів, які охоплюють повний цикл роботи з новинним контентом – від введення даних до отримання результатів аналізу.

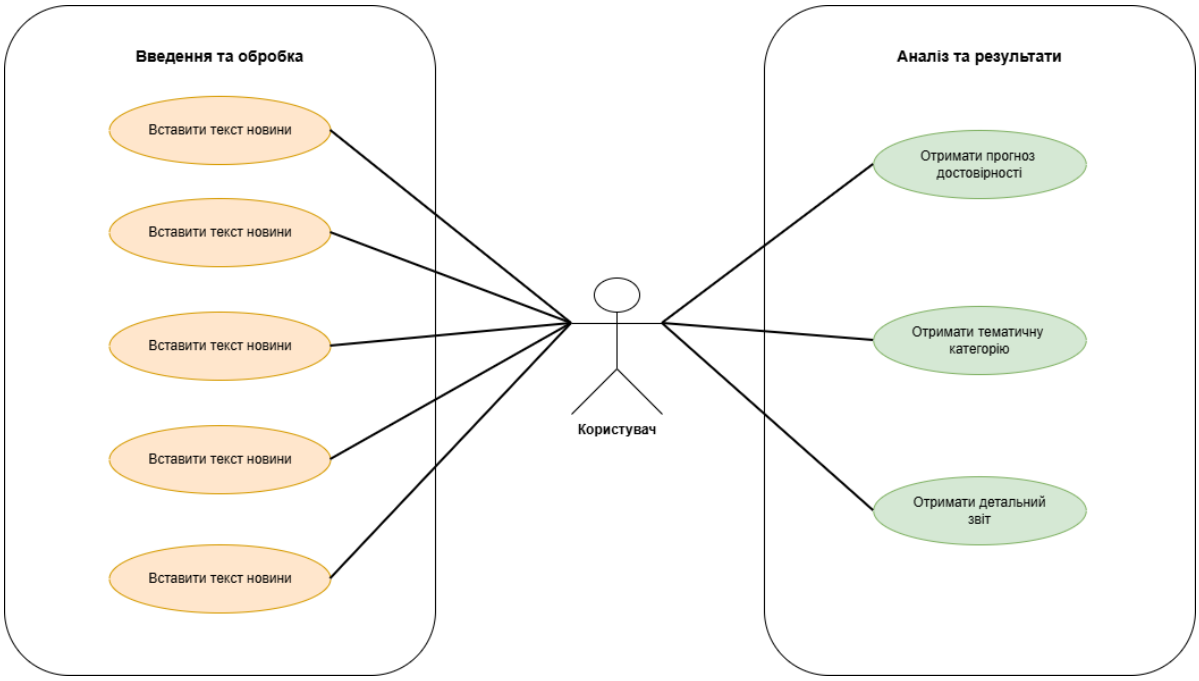

Рисунок 1.1 – Діаграма прецедентів

Функціональні вимоги визначають конкретні функції, операції та можливості, які система має надавати користувачам. Вони описують, що саме система повинна робити у відповідь на певні вхідні дані або в певних ситуаціях.

Система має забезпечувати наступні функціональні можливості:

- Бінарна класифікація новин за критерієм достовірності (правдива/фейкова) з точністю не менше 85% на тестовій вибірці.
- Тематична категоризація контенту для забезпечення контекстуального аналізу та можливості фільтрації результатів за предметними областями.
- Обробка україномовного тексту з підтримкою різних стилів написання (формальний/неформальний, новинний/блоговий формат).
- Попередня обробка вхідного тексту, що включає: токенізацію українського тексту, нормалізацію (приведення до нижнього регістру), видалення стоп-слів на основі українського словника, лематизацію, та векторизацію.

- Веб-інтерфейс має надавати можливість введення тексту новини через текстове поле з підтримкою копіювання/вставки контенту.
- Завантаження файлів форматів CSV (з комою або крапкою з комою як роздільником) та Excel (XLSX) з новинами для пакетної обробки.
- Виконання пакетної обробки множини новин із завантаженого файлу з автоматичним застосуванням обох моделей класифікації до кожного запису та збереження усіх результатів у єдиному звіті.
- Відображення результатів аналізу для кожної новини у форматі карточки або таблиці з чіткою індикацією: відсоток ймовірності фейковості (0-100%), визначена тематична категорія.
- Збереження історії перевірених новин у сесії користувача для можливості порівняння результатів.
- Експорт результатів аналізу у форматі CSV або Excel з включенням наступних полів: оригінальний текст новини, прогноз достовірності (FAKE/TRUE), ймовірність фейковості (%), тематична категорія, дата та час перевірки.
- Адаптивний інтерфейс, що коректно відображається на різних пристроях (десктоп, планшет, смартфон).

Нефункціональні вимоги визначають якісні характеристики системи, такі як продуктивність, надійність, безпека, масштабованість та зручність використання. Вони описують не що система робить, а як вона це робить, встановлюючи стандарти якості та обмеження, за яких система має функціонувати.

Система має відповідати наступним нефункціональним вимогам:

1. Продуктивність та масштабованість:
   - Час відгуку веб-інтерфейсу - не більше 1 секунди при стандартному інтернет-з'єднанні.
   - Архітектура має забезпечувати можливість горизонтального масштабування для обробки зростаючих обсягів даних.
2. Надійність та доступність:

- У разі виникнення помилки обробки (некоректний формат даних, занадто короткий текст, технічний збій) система має відображати зрозуміле повідомлення для користувача без розкриття внутрішніх технічних деталей або трасування стеку помилок.
- Передбачити обробку виключних ситуацій (некоректний формат вхідних даних, обрив з'єднання) з коректним інформуванням користувача.
- Система має зберігати працездатність при роботі з текстами, що містять помилки правопису, опечатки, повтори символів або нестандартні розділові знаки без критичних збоїв.

3. Зручність використання:
   - Інтерфейс має бути інтуїтивно зрозумілим для користувачів без технічної підготовки або попереднього досвіду роботи з системами машинного навчання.
   - Інтерактивні елементи мають мати зрозумілі підказки та описи.
   - Швидкий час навчання для роботи з системою новому користувачу.
   - Інтерфейс має бути українською мовою з чіткими формулюваннями всіх елементів без технічного жаргону.
4. Підтримка та розширюваність:
   - Вихідний код має бути опублікований як open-source на платформі GitHub для можливості подальшого розвитку дослідниками та розробниками.
   - Код має бути задокументований з коментарями для ключових функцій та класів згідно зі стандартом PEP 257 для Python docstrings.
   - README файл у репозиторії має містити: детальні інструкції з встановлення залежностей, крок-за-кроком гайд з розгортання системи локально та на сервері, опис структури проєкту та призначення кожного модуля.

5. Сумісність:
    - Веб-додаток має коректно працювати у сучасних браузерах останніх двох версій.
    - Підтримка роботи на операційних системах Windows, macOS, Linux.
    - Файли для пакетної обробки мають підтримувати стандартні формати: CSV з комою як роздільником, CSV з крапкою з комою (для Excel), Excel XLSX.
6. Етичні вимоги та прозорість:
    - Рішення моделей машинного навчання мають супроводжуватися поясненнями (Explainable AI) через відображення найбільш значущих слів та фраз, що вплинули на класифікацію.
    - Система має включати чітко видиме застереження про те, що результати є автоматичними прогнозами моделей машинного навчання і можуть містити помилки, рекомендуючи додаткову перевірку інформації через офіційні джерела для критично важливих ситуацій.
    - Результати класифікації не мають представлятися як абсолютна істина, а лише як допоміжний інструмент для користувача у процесі критичного осмислення інформації.

Сформульовані вимоги слугують основою для проєктування архітектури системи, вибору технологій та методів машинного навчання, а також для подальшого тестування та валідації розробленого рішення. Дотримання цих вимог забезпечить створення функціональної, надійної та зручної системи для автоматичного виявлення фейкових новин, яка відповідатиме потребам українських користувачів у боротьбі з дезінформацією в сучасному цифровому інформаційному просторі.